

Détection de profils biologiques atypiques par méthode Z-score

Analyse de biomarqueurs sanguins · Ferritine & Fer sérique · 30 individus

Mathis BENTO AFONSO
Margot MARCIANO
Arthur RENAULT-CLÉQUIN

29/03/2026

Plan de la présentation

01

Contexte

Biomarqueurs, population, structure des données

02

Méthode univariée (M1)

Statistique T_n — détection des valeurs extrêmes

03

Méthode saisonnière (M2)

Extension temporelle : deux saisons

04

Méthode multivariée (M3)

Analyse conjointe des deux biomarqueurs

05

Résultats

Seuils 0.95 vs 0.80 — individus détectés

06

Conclusion

Bilan & perspectives

01 — Contexte

Objectif

Identifier des individus présentant des profils biologiques anormaux à partir de séries temporelles de mesures sanguines.

Population

30 individus · Données manquantes fréquentes
Certains individus ont < 3 mesures → exclus de l'analyse

Source

Fichiers : ferritine.xls & fer_serique.xls
Format initial wide → transformé en format long (ID, marqueur, valeur)

Biomarqueurs analysés

Fe
stk

Ferritine

Protéine de stockage du fer
Valeurs normales : 12–300 µg/L

Fe
séq

Fer sérique

Fer circulant dans le sang
Valeurs normales : 10–30 µmol/L

30

Individus

~10

Mesures / ind. (moy.)

≥3

Mesures requises

01 — Analyse descriptive des biomarqueurs

Ferritine — statistiques clés

Min : 12,41 $\mu\text{g/L}$ · Max : 388,02 $\mu\text{g/L}$
Médiane : ~74 · Moyenne : ~104 · Écart-type : ~82


Fer sérique — statistiques clés

Min : 6,14 $\mu\text{mol/L}$ · Max : 36,40 $\mu\text{mol/L}$
Médiane : ~17 · Moyenne : ~17 · Écart-type : ~6


Observations importantes

- Distribution asymétrique pour la ferritine (valeurs extrêmes hautes)
- Le fer sérique est plus symétrique
- Nombreuses valeurs manquantes : certains individus ont seulement 1–2 mesures
- Minimum de 3 observations requis pour calculer la statistique Tn

Nombre de mesures par individu — Ferritine



Nombre de mesures par individu — Fer sérique



01 — Le piège : données insuffisantes

Le piège mentionné dans le sujet

Un petit nombre d'individus (<10) présentent des données si peu nombreuses (1 ou 2 mesures) qu'aucune statistique T_n ne peut être calculée. Ces individus sont systématiquement exclus de toutes les analyses, ce qui peut masquer de vraies anomalies.

Individus exclus (< 3 mesures exploitables) :

Ind. 6 2 obs.	Ind. 7 0 obs.	Ind. 8 1 obs.	Ind. 9 2 obs.	Ind. 10 1 obs.
Ind. 13 1 obs.	Ind. 16 0 obs.	Ind. 18 2 obs.	Ind. 19 1 obs.	Ind. 23 2 obs.

Conséquence

On manque de recul sur ces individus pour repérer d'éventuelles anomalies. Il serait nécessaire d'augmenter la fréquence de prélèvement pour les inclure dans les analyses futures.

02 — Méthode univariée : statistique Tn

Formules clés :

$$T_n = \max_{i \in \{1, \dots, n\}} \left| \frac{X_i - \bar{X}_{n,-i}}{\hat{\sigma}_{n,-i} \sqrt{1 + \frac{1}{n-1}}} \right|$$

$$\hat{\sigma}_{n,-i}^2 = \frac{1}{n-2} \sum_{k=1, k \neq i}^n (X_k - \bar{X}_{n,-i})^2$$

1

Leave-one-out

Pour chaque mesure X_i , on calcule la moyenne et l'écart-type de toutes les autres valeurs de l'individu ($n-1$ valeurs)

2

Score normalisé

On normalise l'écart entre X_i et la moyenne des autres, pondéré par l'écart-type leave-one-out

3

Maximum

On retient la valeur max parmi tous les scores → c'est T_n pour cet individu

4

Comparaison au seuil

T_n est comparé à un seuil tabulé dépendant de n et du taux de faux positifs (0.95 ou 0.80)

02 — Résultats méthode univariée (seuil 0.95)

Fer sérique

**0 individu
anormal**

Aucun Tn ne dépasse
le seuil pour $\alpha=0.95$

Ferritine

**1 individu
anormal**

Individu 11 : Tn > seuil
(n = 8 mesures)

Individus exclus

10 individus exclus
(< 3 mesures)

IDs : 6, 7, 8, 9, 10,
13, 16, 18, 19, 23

Focus individu 11 — Ferritine :

Individu	Biomarqueur	Tn calculé	n obs.	Seuil ($\alpha=0.95$)	Décision
11	Ferritine	4.16	8	4.15	⚠ ANORMAL

03 — Contraintes d'échantillon (M2)

!

Contrainte : $n \text{ total} > 3$

Division par zéro si $n \leq 3$

Dénominateur : $(n - 3)$

$n = 3 \Rightarrow 0 / 0$

Individu exclu si $n \text{ total} \leq 3$

$$T_n = \max \left\{ \max_{i \in \{1, \dots, n_1\}} \left| \frac{X_i - \bar{X}_{n_1, -i}}{\hat{\sigma}_{X, -i, Y} \sqrt{1 + \frac{1}{n_1 - 1}}} \right|, \max_{j \in \{1, \dots, n_2\}} \left| \frac{Y_j - \bar{Y}_{n_2, -j}}{\hat{\sigma}_{Y, -j, X} \sqrt{1 + \frac{1}{n_2 - 1}}} \right| \right\}$$

avec $\bar{X}_{n_1, -i}$ et $\bar{Y}_{n_2, -j}$ les moyennes des observations dans ces 2 saisons:

$$\bar{X}_{n_1, -i} = \frac{1}{n_1 - 1} \sum_{k=1, k \neq i}^{n_1} X_k, \quad \bar{Y}_{n_2, -j} = \frac{1}{n_2 - 1} \sum_{k=1, k \neq j}^{n_2} Y_k$$

et $\hat{\sigma}_{X, -i, Y}^2$ et $\hat{\sigma}_{Y, -j, X}^2$ les variances respectives de chaque saison:

$$\hat{\sigma}_{X, -i, Y}^2 = \frac{1}{n - 3} \left(\sum_{k=1, k \neq i}^{n_1} (X_k - \bar{X}_{n_1, -i})^2 + \sum_{k=1}^{n_2} (Y_k - \bar{Y}_{n_2})^2 \right)$$

03 — Méthode saisonnière : extension temporelle

Idee : les valeurs biologiques peuvent varier selon la saison → on sépare les prélèvements en 2 groupes (pair / impair)

Attribution des saisons

Saison 1 (X)

ferser1, ferser3, ferser5, ... · Indices impairs

Saison 2 (Y)

ferser2, ferser4, ferser6, ... · Indices pairs

Résultats (seuil $\alpha = 0.95$)

Aucune anomalie

Nouveautés par rapport à M1

- La variance est calculée sur l'ensemble des données (deux saisons) mais en excluant l'observation testée
- Le T_n retenu est le MAX des deux scores saisonniers
- Les seuils tabulés tiennent compte de n_1 et n_2 séparément

04 — La règle des 4 paires (M3)

4

paires min.

Fer + Ferritine simultanés

Condition d'application

$n \geq 4$ paires complètes
(Fer sérique + Ferritine mesurés simultanément)

Raison mathématique

$$\bar{X}_{n,-i} = \frac{1}{n-1} \sum_{k=1, k \neq i}^n X_k$$
$$C_{n,-i} = \frac{1}{n-1-d} \sum_{k=1, k \neq i}^n (X_k - \bar{X}_{n,-i}) (X_k - \bar{X}_{n,-i})'$$

$n = 3 \Rightarrow \text{dénom.} = 0 \Rightarrow \text{division par } 0$

Individu exclu si n paires < 4

04 — Méthode multivariée : Fer sérique + Ferritine

Principe : analyser simultanément les 2 biomarqueurs en tenant compte de leur corrélation

Statistique T_n multivariée ($d=2$)

$$T_n = \frac{n-1}{nd} \max_{i \in \{1, \dots, n\}} (X_i - \bar{X}_{n,-i})' C_{n,-i}^{-1} (X_i - \bar{X}_{n,-i})$$

$d = 2$ biomarqueurs — distance de Mahalanobis leave-one-out

Matrice de covariance $C_{n,-i}$

Estimée sur $n-1$ observations (leave-one-out)
Capture la corrélation entre les deux marqueurs

Individus utilisables

Seules les paires de mesures complètes (fer sérique ET ferritine disponibles pour le même prélèvement) sont retenues
→ Réduit encore la taille d'échantillon disponible

Résultats (seuil $\alpha = 0.95$)

ID	Tn multivarié	n paires	Seuil	Décision
24	18.78	8	16.47	⚠ ANORMAL
28	55.80	8	16.47	⚠ ANORMAL
11	15.87	8	16.47	Limite (< seuil)
25	17.99	7	21.54	Limite (< seuil)

→ 2 individus clairement anormaux (24 & 28)

→ 2 individus très limites (11 & 25)

05 — Impact du seuil : $\alpha=0.95$ vs $\alpha=0.80$

Baisser le seuil de $\alpha=0.95$ à $\alpha=0.80$ réduit la sensibilité → on accepte plus de faux positifs, et on détecte davantage d'anomalies.

Méthode / Marqueur	$\alpha = 0.95$	$\alpha = 0.80$	Nouveaux détectés
M1 — Fer sérique	0 anormal	Ind. 5, 24 (2)	+2 individus
M1 — Ferritine	Ind. 11 (1)	Ind. 11, 27 (2)	+1 individu
M2 — Fer sérique	0 anormal	Ind. 2, 21, 29 (3)	+2 individus
M2 — Ferritine	0 anormal	0 anormal	Aucun changement
M3 — Multivarié	Ind. 24, 28 (2)	Ind. 11, 21, 24, 25, 28 (5)	+3 individus

Conclusion seuil


$\alpha=0.80$ détecte plus d'anomalies mais augmente le risque de faux positifs (individus normaux classifiés comme anormaux).

Point clé

Le choix du seuil est crucial : il dépend du contexte médical et du coût associé à chaque type d'erreur.

05 — Synthèse : individus détectés

Récapitulatif des anomalies détectées selon la méthode et le seuil ($\alpha = 0.95$)



Individus notables

Ind. 11

Ferritine anormale (M1)
Détecté également en M3 (limite)

Ind. 21

Fer sérique anormal (M2) $\alpha=0.80$
Détecté en M3 avec $\alpha=0.80$

Ind. 24

Anormal en M3 ($T_n=18.78$)
Également détecté M1 Fer ($\alpha=0.80$)

Ind. 28

Cas le plus flagrant : $T_n=55.80$
Détecté uniquement en M3

Conclusion

Méthode Z-score efficace

La statistique T_n leave-one-out permet d'identifier des valeurs extrêmes individuelles sans hypothèse forte sur la distribution.

Cas limite (valeur proche du seuil) :

Ind. 30 (M1 Ferritine $\alpha=0.80$) : $T_n=2.85$ vs seuil=2.90

La temporalité apporte peu ici

La méthode saisonnière (M2) ne détecte aucune anomalie à un seuil strict ($\alpha=0.95$) sur ce jeu de données. La saisonnalité n'est pas un facteur pertinent.

L'approche multivariée est puissante

M3 capture des anomalies invisibles en univarié en exploitant la corrélation entre les deux biomarqueurs (individu 28 : $T_n=55.8$!).

Cas limites (valeur proche du seuil) :

Ind. 11 (M3) : $T_n=15.87$ vs seuil=16.47 (très proche)

Ind. 25 (M3) : $T_n=17.99$ vs seuil=21.54

Le choix du seuil est décisif

Passer de $\alpha=0.95$ à $\alpha=0.80$ multiplie les détections mais augmente le taux de faux positifs. Ce choix est médical avant tout.