

Analyse et Prévision du Halo Chômage des Jeunes en France

BUTSD 2FI EMS

Riveen Wickramasinghe, Sarah Bouzhama, Mathis Bento-Afonso

16 décembre 2025

Table des matières

Introduction	2
1. Préparation et exploration des données	2
1.1 Chargement et nettoyage des données	2
1.2 Construction de la série temporelle	2
2. Analyse de la tendance	2
2.1 Filtre de moyennes mobiles centrées	2
2.2 Régression linéaire sur les moyennes annuelles	4
3. Décomposition et analyse de la saisonnalité	4
3.1 Décomposition additive classique	4
3.2 Interprétation des coefficients saisonniers	5
3.3 Série désaisonnalisée	6
3.4 Analyse des résidus	6
4. Prévision et comparaison de trois méthodes	6
4.1 Protocole d'évaluation	6
4.2 Trois méthodes de prévision	7
4.3 Évaluation comparative (EQM)	8
4.4 Visualisation des prévisions	8
4.5 Prévision finale (2 ans)	9
Conclusion	10
Répartition des tâches	10
Summary (in English)	11

Introduction

Le chômage des jeunes représente un enjeu majeur pour les sociétés modernes, tant sur le plan économique que social. L’Institut National de la Statistique et des Études Économiques (INSEE) produit régulièrement des données détaillées sur l’emploi et le chômage en France. Parmi ces indicateurs figure le **halo autour du chômage**, qui englobe non seulement les chômeurs au sens du BIT, mais aussi les personnes sans emploi qui ne répondent pas à l’une des conditions du chômage strict (disponibilité immédiate ou recherche active).

Ce rapport s’inscrit dans une démarche de description et de prévision de séries temporelles. Notre objectif est triple : (1) analyser la dynamique de la série chronologique du halo chômage des jeunes (15–24 ans) en France (hors Mayotte) entre 2003 et 2025 ; (2) identifier et quantifier ses composantes principales (tendance, saisonnalité, irrégularité) ; (3) proposer et comparer trois méthodes de prévision (ETS, ARIMA automatique, naïve saisonnière) sur une période de test historique avant de produire une prévision prospective.

Les données utilisées proviennent du fichier `chomage_jeunes_trimestrielles25.csv` et couvrent une période riche en transformations économiques et sociales : crise financière de 2008–2009, réformes du marché du travail, pandémie de COVID-19 et retour progressif à une situation plus stable.

1. Préparation et exploration des données

1.1 Chargement et nettoyage des données

L’importation des données a été effectuée en tenant compte des spécificités du fichier CSV fourni par l’INSEE : séparateur point-virgule, décimales en virgule (format français), et présence de métadonnées en en-tête. Après lecture, la base de données comporte 91 observations, réparties sur deux colonnes : la date au format « Année-Trimestre » et le nombre de jeunes dans le halo du chômage en milliers.

Aucune valeur manquante n’a été détectée dans la colonne « Nombre ». Les données ont été triées chronologiquement du plus ancien au plus récent, garantissant une cohérence temporelle pour les analyses ultérieures.

1.2 Construction de la série temporelle

La série temporelle a été construite avec une fréquence de 4 (données trimestrielles), couvrant la période du 2003-T1 au 2025-T2. L’objet « `ts` » ainsi créé permet l’utilisation des fonctions spécialisées en séries temporelles et prévisions du package `forecast`.

Le graphique révèle une évolution marquée par plusieurs phases : une hausse entre 2003 et 2009 (crise financière), un pic autour de 2012–2013, puis une baisse progressive jusqu’à 2019, une augmentation associée à la crise du COVID-19 (2020–2021), et une tendance à la baisse ensuite. Ces oscillations suggèrent une forte sensibilité du halo chômage des jeunes aux cycles économiques.

2. Analyse de la tendance

2.1 Filtre de moyennes mobiles centrées

La tendance de long terme a été estimée en appliquant une moyenne mobile centrée d’ordre 4, qui lisse la composante saisonnière tout en préservant les ruptures structurelles importantes.

Évolution du halo chômage des jeunes (15–24 ans)




Figure 1: Évolution du halo chômage des jeunes en France (2003-2025)

Tendance par moyennes mobiles centrées




Figure 2: Série originale et tendance par moyennes mobiles centrées

La tendance lissée confirme les observations précédentes : un pic vers 2012–2013 suivi d’une décroissance quasi-linéaire jusqu’à 2019, une interruption temporaire liée à la pandémie, puis une reprise à la baisse. Cette courbe lissée facilite l’interprétation des mouvements de fond en écartant les fluctuations trimestrielles court-termistes.

2.2 Régression linéaire sur les moyennes annuelles




Figure 3: Moyennes annuelles et droite de régression linéaire

La régression linéaire sur les moyennes annuelles met en évidence une pente positive, traduisant une hausse du niveau moyen annuel du halo du chômage des jeunes sur l’ensemble de la période étudiée. Cette tendance globale reste toutefois compatible avec des phases de baisse sur certaines sous-périodes (par exemple après le pic 2012–2013), car la droite de régression résume l’évolution moyenne sur l’ensemble de l’horizon. Enfin, l’écart des points autour de la droite (visible sur le graphique) montre que la tendance linéaire ne capture qu’imparfaitement la complexité des fluctuations observées.

3. Décomposition et analyse de la saisonnalité

3.1 Décomposition additive classique

Pour isoler les composantes de la série, une décomposition additive a été appliquée, supposant que la série s’écrit comme la somme de quatre éléments : la tendance T_t , la saisonnalité S_t , la composante irrégulière E_t et la valeur moyenne.




Figure 4: Décomposition additive de la série

Le premier panneau reproduit la série originale. Le deuxième montre la tendance (lissée), le troisième isole la saisonnalité, et le quatrième affiche les résidus (composante irrégulière).

Coefficients saisonniers (en milliers) :

T1 : -1.344

T2 : 4.71

T3 : -5.859

T4 : 2.493

3.2 Interprétation des coefficients saisonniers

Les coefficients saisonniers révèlent un **pattern trimestriel distinct** : certains trimestres affichent systématiquement des niveaux plus élevés (ou plus faibles) que la moyenne du trimestre donné. Ces variations régulières reflètent des phénomènes réels tels que : - L'entrée et la sortie du marché du travail des jeunes diplômés (juin pour les licenciés, septembre-octobre pour la reprise d'études) ; - Les variations d'activité économique saisonnière (moindre embauche en hiver) ; - Les politiques scolaires et universitaires (calendrier des examens, périodes de stage).

La magnitude relative des coefficients saisonniers indique que la saisonnalité est **modérée mais significative** et doit être prise en compte pour une modélisation précise.

Série corrigée des variations saisonnières (CVS)




Figure 5: Série corrigée des variations saisonnières (CVS)

3.3 Série désaisonnalisée

La série désaisonnalisée (CVS) offre une vision épurée des mouvements court et moyen terme du halo du chômage. En supprimant l'effet de saisonnalité régulière, elle fait mieux ressortir les ruptures structurelles et les chocs temporaires (comme la crise de 2008-2009 ou la pandémie de 2020). On observe une volatilité résiduelle non-négligeable, notamment durant les périodes de crise, attestant de l'importance de la composante irrégulière.

3.4 Analyse des résidus

Les boxplots des résidus par trimestre révèlent une **distribution relativement symétrique autour de zéro** pour chaque trimestre, ce qui valide le modèle additif. Cependant, on note la présence de quelques valeurs extrêmes (outliers) qui correspondent probablement aux périodes de forte perturbation économique (crises, pandémie). L'absence d'asymétrie marquée par trimestre indique qu'aucune saisonnalité résiduelle importante n'a été omise.

4. Prévision et comparaison de trois méthodes

4.1 Protocole d'évaluation

Pour évaluer la qualité des prévisions, un protocole rigoureux a été mis en place : - **Données d'entraînement (train)** : du T1 2003 au T4 2022 (80 observations). - **Données de test** : du T1




Figure 6: Boxplots des résidus par trimestre

2023 au T2 2025 (9 observations). - **Horizon de prévision** : 9 trimestres. - **Critère de performance** : l'erreur quadratique moyenne (EQM), définie comme $EQM = \frac{1}{n} \sum_{t=1}^n (\hat{y}_t - y_t)^2$, où $\hat{y}_t$ est la prévision et y_t la valeur observée.

4.2 Trois méthodes de prévision

Méthode 1 : Lissage exponentiel (ETS)

Le lissage exponentiel, ou **Exponential Smoothing** (ETS), est une approche flexible qui donne plus de poids aux observations récentes. La sélection du modèle optimal (additif ou multiplicatif, avec ou sans tendance) est effectuée automatiquement via l'algorithme AICc.

Méthode 2 : ARIMA automatique (SARIMA)

L'approche **ARIMA** (AutoRegressive Integrated Moving Average) modélise la série comme fonction de ses valeurs passées et des chocs passés. La fonction `auto.arima()` sélectionne automatiquement les ordres p , d , q et les termes saisonniers P , D , Q en minimisant le critère d'information.

Méthode 3 : Naïve saisonnière (benchmark)

La méthode **naïve saisonnière** (snaive) constitue un benchmark simple : la prévision pour un trimestre donné est égale à la valeur observée au même trimestre l'année précédente. Bien que simpliste, cette méthode sert souvent de référence de performance minimale.

4.3 Évaluation comparative (EQM)

Table 1: Erreur quadratique moyenne par méthode sur la période de test

Methode	EQM
ETS	4757.049
ARIMA automatique	4513.761
Naïve saisonnière	6690.111

Résultats : L'EQM la plus faible désigne la méthode offrant les prévisions les plus précises sur la période de test. Cette comparaison fournit une évaluation objective de la capacité de chaque méthode à anticiper les mouvements réels du halo du chômage entre 2023 et 2025.

4.4 Visualisation des prévisions




Figure 7: Prévisions comparées et données observées (T1 2023 – T2 2025)

Le graphique compare visuellement les trois prévisions aux valeurs effectivement observées durant la période de test. Les écarts visibles entre les courbes de prévision et la réalité illustrent les défis propres à la modélisation du chômage des jeunes, notamment la difficulté à anticiper les ruptures structurelles ou les chocs exogènes.

4.5 Prévision finale (2 ans)

Le meilleur modèle (selon l'EQM) est réajusté sur l'ensemble du dataset puis utilisé pour produire une prévision prospective pour les 8 trimestres suivants (du T3 2025 au T2 2027).




Figure 8: Prévisions finales pour les deux années suivantes

Prévisions pour les 8 trimestres suivants :

##	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
##	2025	Q3	584.9883	549.8007	620.1758	531.1736 638.8029
##	2025	Q4	568.3905	528.8045	607.9766	507.8489 628.9322
##	2026	Q1	581.6964	534.1153	629.2775	508.9274 654.4654
##	2026	Q2	582.3982	529.8105	634.9860	501.9722 662.8243
##	2026	Q3	585.4583	530.5584	640.3581	501.4962 669.4204
##	2026	Q4	587.3755	529.2882	645.4629	498.5386 676.2124
##	2027	Q1	589.8466	529.2032	650.4899	497.1006 682.5925
##	2027	Q2	592.0492	528.7409	655.3576	495.2275 688.8710

Conclusion

Cette étude a permis une **analyse complète et multidimensionnelle** de la série chronologique du halo chômage des jeunes en France sur plus de 20 années. Les principaux enseignements sont :

1. **Tendance générale** : Malgré des fluctuations cycliques marquées (crises, pandémie), l'évolution est non monotone : hausse jusqu'à un pic autour de 2012–2013, baisse progressive jusqu'à 2019, hausse temporaire durant 2020–2021, puis repli récent. Sur l'ensemble 2003–2025, l'ajustement linéaire sur moyennes annuelles suggère une tendance moyenne légèrement croissante, tout en soulignant que la dynamique dépend fortement des sous-périodes considérées.
2. **Saisonnalité** : La série exhibe une **saisonnalité modérée mais régulière**, attribuable aux calendriers scolaires, aux périodes d'embauche et aux cycles économiques. Ces variations saisonnières doivent être ajustées pour l'analyse des tendances court-moyen terme.
3. **Performance prédictive** : Parmi les trois méthodes testées, le modèle **ARIMA automatique** (ou **ETS**, selon l'EQM) offre le meilleur compromis entre précision et parcimonie. Les prévisions produites sont cohérentes avec les dynamiques observées et peuvent servir de base à l'anticipation des politiques publiques en matière d'emploi des jeunes.
4. **Implications** : Les prévisions prospectives (2 ans) suggèrent une relative **stabilisation** du halo chômage des jeunes autour de niveaux proches de ceux observés récemment, avec possibilité de fluctuations saisonnières importantes.

En perspective, on pourrait enrichir cette analyse en intégrant des **variables externes** (croissance du PIB, politiques actives de l'emploi, dynamiques démographiques) pour mieux comprendre les déterminants du halo chômage et améliorer la qualité des prévisions.

Répartition des tâches

- **Sarah BOUZHAMA** : collecte et nettoyage des données, construction de la série temporelle, analyse descriptive, analyse de la tendance (moyennes mobiles et régression), rédaction des sections 1 et 2, relecture générale.
- **Riveen WICKRAMASINGHE** : mise en place du document R Markdown et structuration du rendu, décomposition additive, analyse de la saisonnalité et des résidus, implémentation des trois modèles de prévision (ETS, ARIMA automatique, naïve saisonnière), évaluation comparative par EQM, prévision finale, rédaction des sections 3 et 4.
- **Mathis Bento** : validation et reproductibilité des analyses (vérification du code, cohérence des sorties), production de graphiques complémentaires, relecture technique, rédaction de la conclusion.

Summary (in English)

This report analyses the quarterly time series of young people (aged 15–24) in the halo around unemployment in France from 2003 to 2025. After data cleaning and construction of a time series object, we investigate long-term trends using centred moving averages and linear regression on annual means. We perform a classical additive decomposition to isolate trend, seasonal and irregular components. The seasonally adjusted series is then examined, with particular attention to residual behaviour via boxplots.

Three forecasting methods are compared on a hold-out test period (Q1 2023 to Q2 2025) using the mean squared error (MSE) criterion: exponential smoothing (ETS), automatic ARIMA, and seasonal naïve as a benchmark. The best-performing model is subsequently refit to the entire dataset and used to generate prospective forecasts for the following two years. Key findings highlight non-monotonic dynamics: an increase up to 2012–2013, a decline until 2019, a temporary rise during 2020–2021, and a recent decrease. Over the full sample, the linear fit on annual means suggests a slightly upward average trend, alongside moderate but significant seasonality. Forecasts suggest relative stabilization of youth unemployment halo in the coming years, with continued seasonal variation. Results provide evidence for public policy decisions regarding youth employment and labour market integration.
